

Programa de Pós-Graduação em Ciências da
Computação

Processamento Digital de Imagens - PDI

Relatório 3

Questões 21 a 25

Discente:

Carlos Estevão Bastos Sousa - **20181018030043**

Docente:

Prof. Dr. Pedro Pedrosa Rebouças Filho

Fortaleza, 27 de novembro de 2018

Sumário

Crescimento de Regiões em Imagens Binárias	3
Crescimento de Regiões em Imagens Tons de Cinza	4
Método K-means em Imagens Tons de Cinza	6
Transformada de Hough	8
Transformada de Watershed em Imagens Tons de Cinza	11
REFERÊNCIAS	13

Crescimento de Regiões em Imagens Binárias

O Crescimento de Regiões funciona como um processo iterativo, o mesmo examina os pixels vizinhos dos pixels-sementes e determina se deverão ou não serem adicionados a uma determinada região. É semelhante a uma limiarização e se inicia através de um conjunto de pixels. Para cada semente é avaliado o valor de seus vizinhos e em seguida, a agregação de regiões é elaborada de acordo com a similaridade das mesmas.

Desta forma, pode-se afirmar que a técnica de segmentação através do crescimento de regiões ocorre em três etapas: escolha dos pixels-sementes (1), escolha do limiar (2) e crescimento de regiões(3).

De acordo com GUIMARAES (2017) o crescimento das regiões em si, constitui-se de fazer o agrupamento de pixels por similaridade em algum critério como intensidade de cinza, textura, etc.




Figura 1 – Processo de Crescimento de Região. As cores da imagem foram invertidas para um melhor resultado. Fonte: autor

Na figura 1, no quadrado superior esquerdo, o ponto vermelho representa o local da escolha do pixel-semente, que foi escolhido através de um clique na imagem. Como a mesma é binária, todos os pixels que contém o mesmo valor foram adicionados, obtendo como resultado final a imagem inferior à direita.

Este tipo de segmentação é bastante utilizado na geração de imagens médicas e na detecção de objetos. Em imagens binárias o processo costuma ocorrer de forma rápida e possuir bons resultados, pois, de certo modo, não há uma preocupação com o valor do *threshold* a ser inserido e requer pouco poder de processamento.

Crescimento de Regiões em Imagens Tons de Cinza

Para LENGRAND-LAMBERT (2011) o método usa um ponto de semente, definido pelo usuário. A região cresce comparando com sua vizinhança. O critério escolhido é uma diferença entre o valor da intensidade do pixel externo e a média da região. O pixel com intensidade mínima na vizinhança da região é escolhido para ser incluído. O crescimento para assim que a diferença é maior que um limiar.

O procedimento elaborado foi semelhante ao método anterior, a diferença ocorreu nos pixels-sementes escolhidos através do clique do mouse.

Abaixo é possível verificar alguns resultados obtidos com o crescimento de regiões iniciados a partir de diversos pontos.

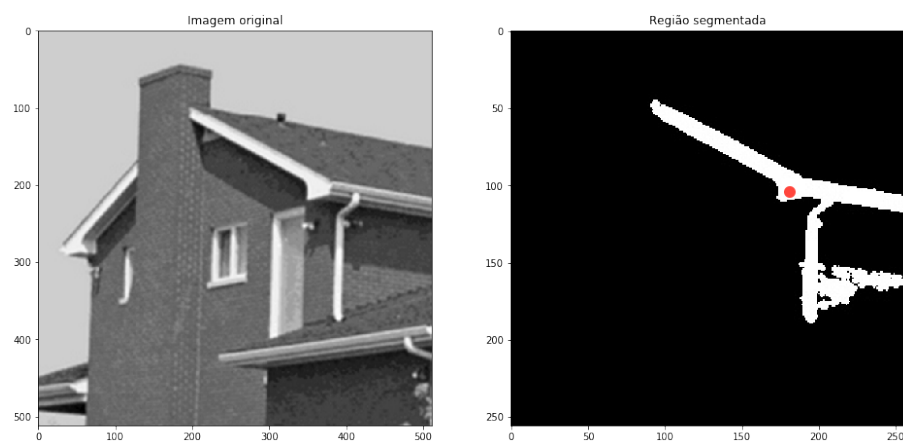


Figura 2 – Processo de Crescimento de Região em imagens tons de cinza. Fonte: autor




Figura 3 – Processo de Crescimento de Região em imagens tons de cinza. Fonte: autor

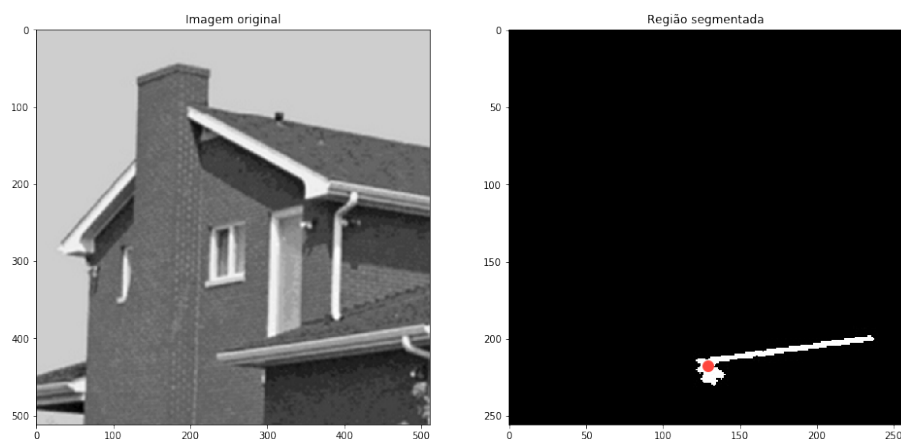


Figura 4 – Processo de Crescimento de Região em imagens tons de cinza. Fonte: autor

É válido lembrar que o processo de crescimento de regiões em imagens tons de cinza gerou maior custo computacional que o método com imagens binárias, desta forma, o segundo se torna mais viável, dependendo do problema a ser solucionado.

Método K-means em Imagens Tons de Cinza

O K-means é um algoritmo de aprendizado de máquina não supervisionado voltado para clustering de regiões, isto é, agrupa um conjunto de dados ao número desejado de grupos.

O mesmo é um método iterativo que pode ser representado de acordo com a seguinte equação:

$$J(C) = \sum_{k=1}^k \sum_{x_i \in c_k} ||x_i - \mu_k||^2 \quad (1)$$

Como citado, este algoritmo é voltado para clustering de regiões, isto é, agrupa um conjunto de dados ao número desejado de grupos(k). O mesmo é dividido em três etapas: distância(1), atribuição do cluster de distância mínima (2) e atualização do centróide do cluster(3). Estas etapas são repetidas até que o algoritmo consiga convergir.

A ideia do K-means é atribuir um pixel a um cluster com base na distância mínima entre o mesmo e o centróide do cluster existente.

Abaixo, é possível verificar alguns resultados obtidos durante a implementação do algoritmo abordado.




Figura 5 – Aplicação do método K-means. Fonte: autor

Vale salientar que o K-means possui fácil implementação, não possui fase de treinamento e deve iniciar com um valor de clusters a ser encontrado, o que pode não gerar bons resultados dependendo do problema em questão, pois, o número de regiões existentes em uma imagem pode ser desconhecido o que pode-se concluir, que o resultado da segmentação depende do tamanho de K e da imagem a ser processada.

Transformada de Hough

Segundo JAMUNDA (2000) a transformada de Hough (HT) é um método padrão para detecção de formas que são facilmente parametrizadas (linhas, círculos, elipses, etc.) em imagens computacionais.

Geralmente, antes de executar essa transformada, as imagens passam por um pré-processamento (redução de ruído, localização de bordas, etc) para posteriormente seguir com a detecção das formas.

Detecção de Círculos

Para detecção de círculos são parametrizados três valores: x , y e r , onde x e y representam a posição do centro e r o raio.

Assim, para a definição de um círculo, temos:

$$C : (X_{center}, Y_{center}, r) \quad (2)$$

Onde X_{center} e Y_{center} definem o ponto central e r é o raio. É válido lembrar que qualquer curva que possa ser representada por uma equação parametrizada, pode ser detectada pela transformada em questão. Assim, temos:

Circunferência:

$$(x - a)^2 + (y - b)^2 = r^2 \quad (3)$$

Elipse:

$$\frac{(x - x_0)^2}{a^2} + \frac{(y - y_0)^2}{b^2} = 1 \quad (4)$$

A seguir, alguns resultados obtidos na aplicação:




Figura 6 – Detecção de Círculos. Fonte: autor

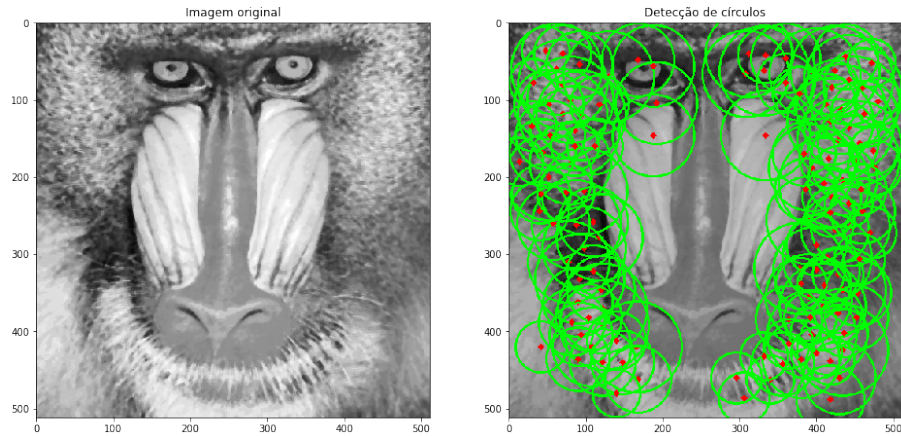


Figura 7 – Detecção de Círculos. Fonte: autor

Detecção de Linhas

Em geral uma linha reta pode ser representada como:

$$y = mx + c \quad (5)$$

Onde m é o coeficiente angular e c a intersecção com y . A equação anterior pode ser reescrita da seguinte forma:

$$c = -mx + y \quad (6)$$

Porém, a detecção de linhas verticais não funcionavam com a equação acima (plano cartesiano). Para isso foi proposta a seguinte equação (coordenadas polares):

$$r = x \cos \theta + y \sin \theta \quad (7)$$

Na qual r é a distância da origem até o ponto mais próximo da linha reta e θ é o ângulo entre o eixo x e a linha que conecta a origem com o ponto mais próximo.

A aplicação da transformada pode ser vista a seguir:




Figura 8 – Detecção de Linhas. Fonte: autor




Figura 9 – Detecção de Linhas. Fonte: autor

Ficou claro que a transformada é bastante importante para a detecção de formas pois, não apresenta alto custo computacional, porém não é muito robusta a ruídos, desta forma, a imagem deverá passar por um pré-processamento para a obtenção de bons resultados.

Transformada de Watershed em Imagens Tons de Cinza

A transformada Watershed é uma técnica de segmentação pertencente a morfologia matemática e foi inspirada na divisão de superfícies em bacias hidrográficas. Na mesma cada pixel corresponde a uma posição e os níveis de cinza representam as altitudes. simplificando, esta transformada procura encontrar pontos em uma superfície na qual uma gota de água possa escorrer.

Para ROSEBROCK (2015) watershed é um algoritmo clássico usado para segmentação e é especialmente útil ao extrair objetos em contato ou sobrepostos em imagens.

Em resumo, as superfícies dos mínimos são inundadas, evitando que águas de diferentes locais se unam com o intuito de obter segmentos de imagens diferentes.

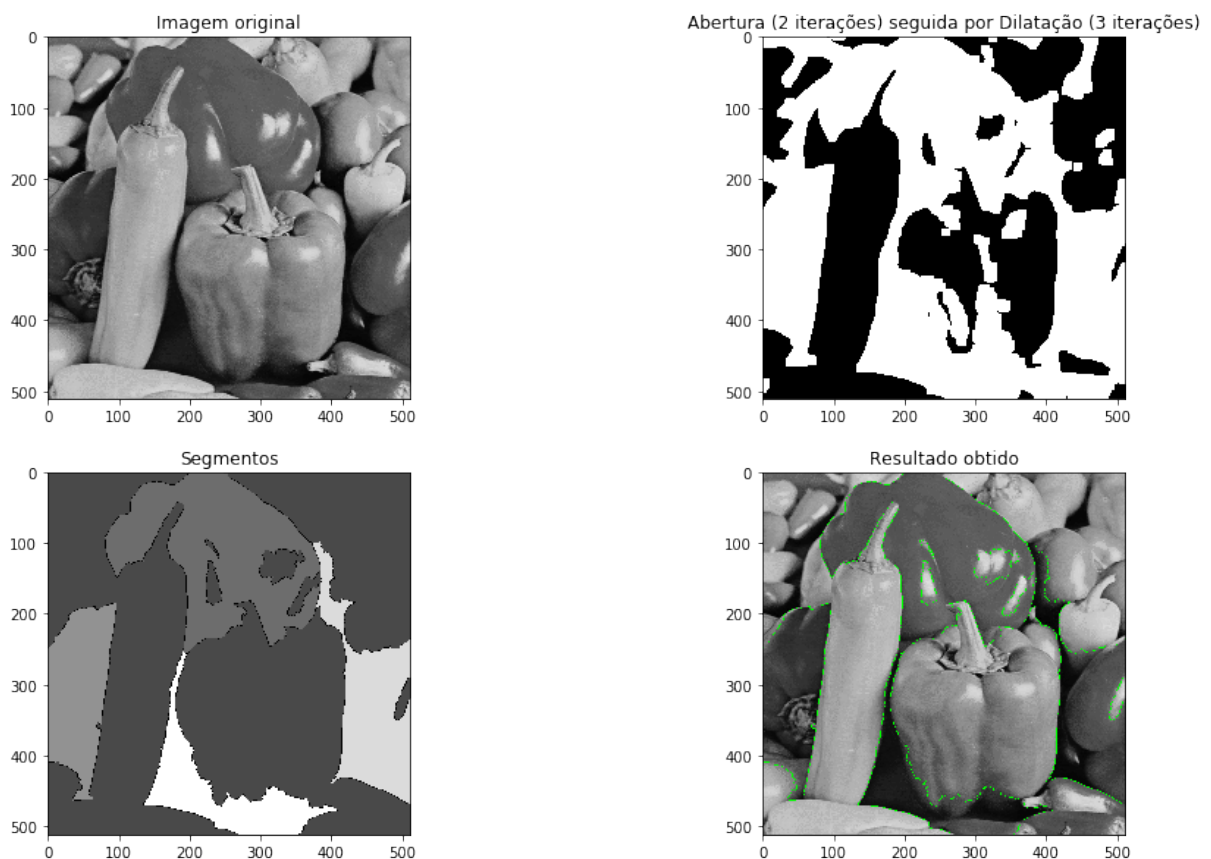


Figura 10 – Aplicação da Transformada de Watershed. Fonte: autor

Conforme pode ser visto na figura 10, a imagem original passou por um processo de

abertura (2 iterações), posteriormente dilatação (3 iterações) para posteriormente inundar os objetos e segmentar os mesmos. É perceptível que o algoritmo obteve bons resultados, pois conseguiu segmentar os objetos de interesse na imagem.

Referências

- GUIMARAES, E. P. E. S. D. *Crescimento de Regiões por Agregação de Pixels*. [S.l.], 2017. Disponível em: <https://www.gta.ufrj.br/grad/07_2/eliseu/CrescimentodeRegiesporAgregaodePixels.html>. Acesso em: 25 nov. 2018. Citado na página 3.
- JAMUNDA, T. *Reconhecimento de Formas: A Transformada de Hough*. [S.l.], 2000. Disponível em: <<http://www.inf.ufsc.br/~aldo.vw/visao/2000/Hough/index.html>>. Acesso em: 24 nov. 2018. Citado na página 8.
- LENGRAND-LAMBERT, J. *A simple region growing implementation in Python*. [S.l.], 2011. Disponível em: <<http://www.lengrand.fr/2011/11/simple-region-growing-implementation-in-python>>. Acesso em: 26 nov. 2018. Citado na página 4.
- ROSEBROCK, A. *Watershed OpenCV*. [S.l.], 2015. Disponível em: <<https://www.pyimagesearch.com/2015/11/02/watershed-opencv/>>. Acesso em: 20 nov. 2018. Citado na página 11.